线性分类模型

《神经网络与深度学习》第4讲

分类问题示例

示例: 图像分类

数据集: CIFAR-10

60000张32x32色彩图像，共10类

每类6000张图像

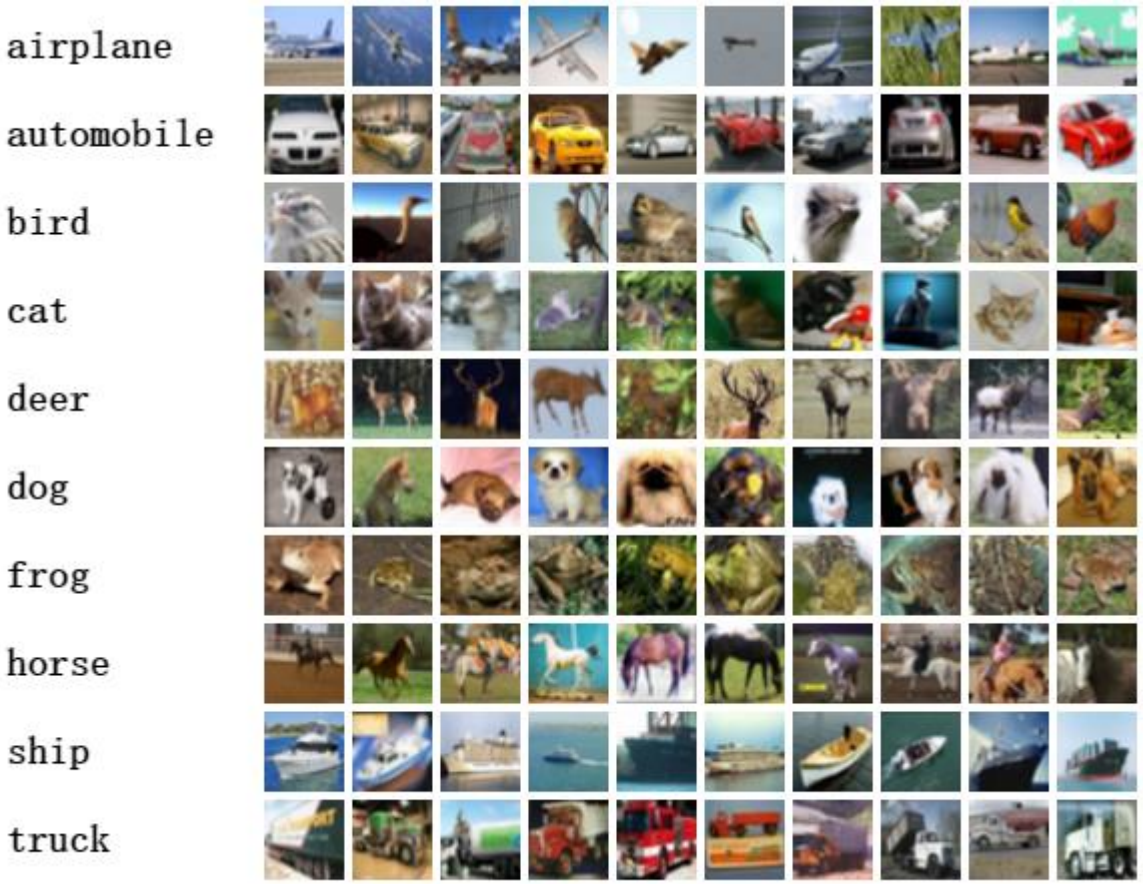

示例: 图像分类

数据集: ImageNet

14,197,122 images, 21841 synsets

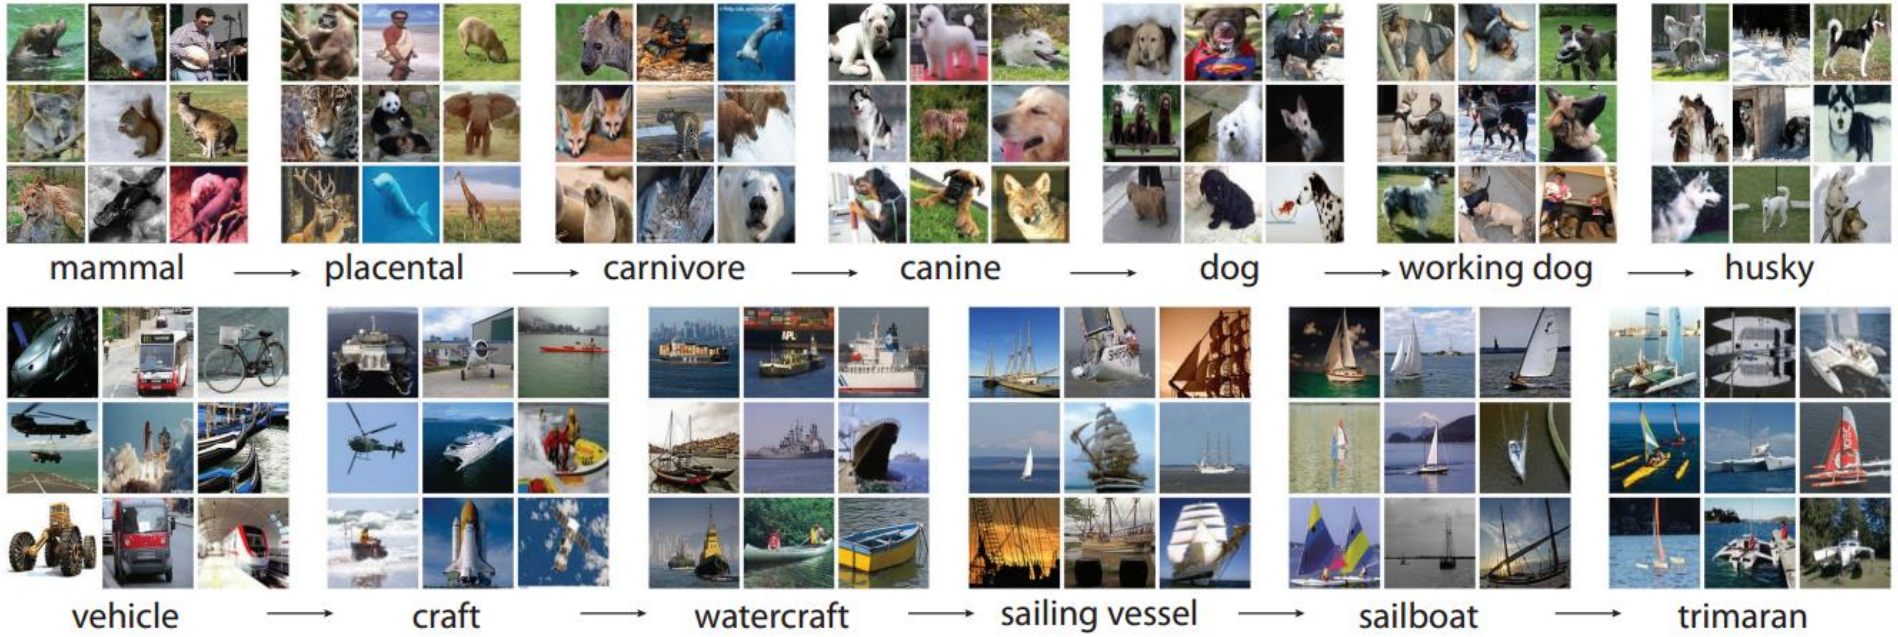

图像分类建模

[32x32x3]
array of numbers 0...1
(3072 numbers total)

image parameters

$f(\mathbf{x}, \mathbf{W})$

10 numbers, indicating class scores

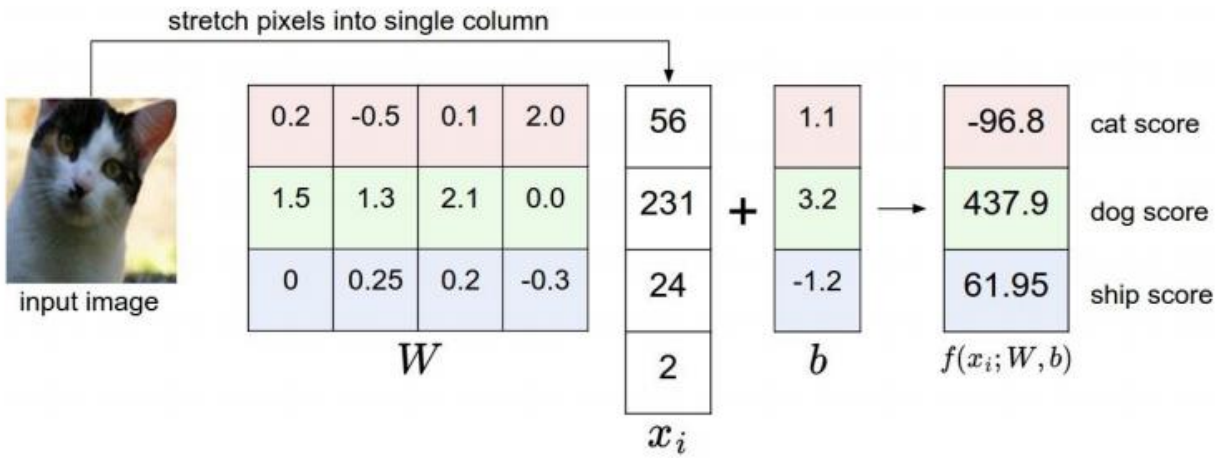

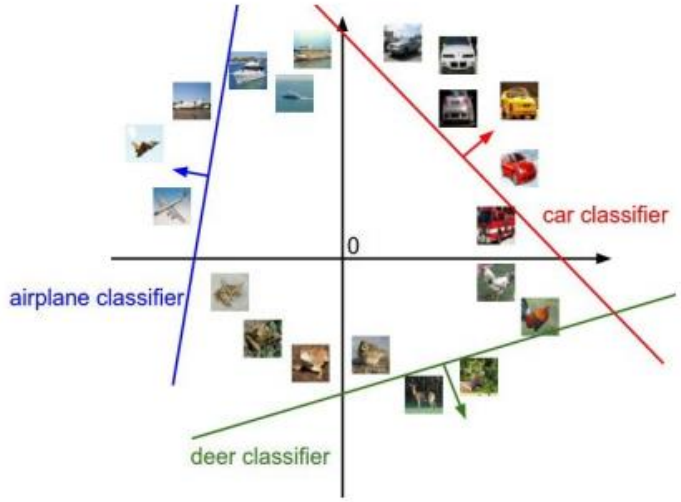

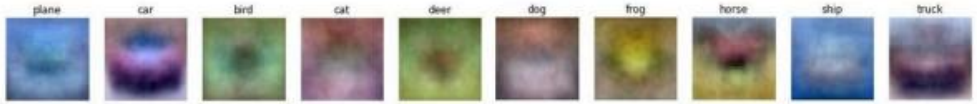

示例：图像分类、目标检测、实例分割

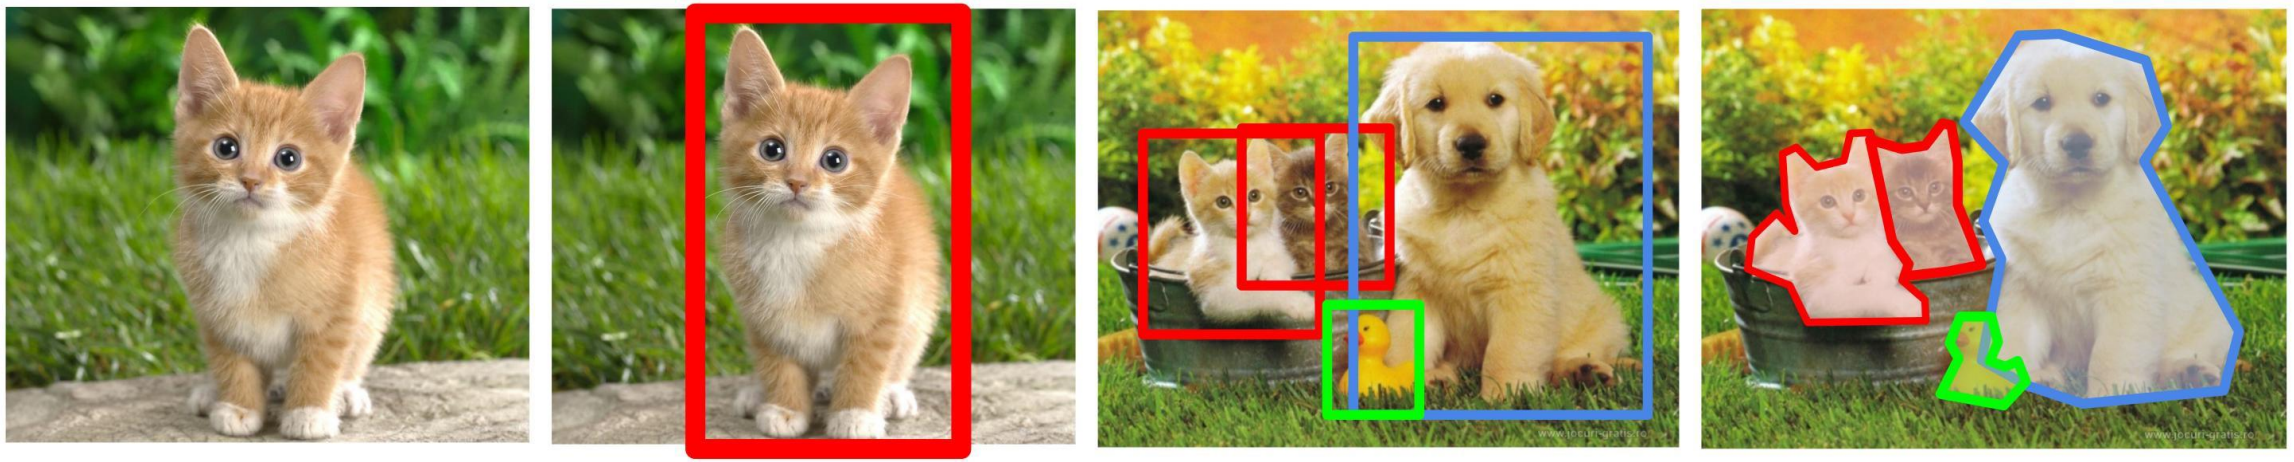

Classification	Classification + Localization	Object Detection	Instance Segmentation
CAT	CAT	CAT, DOG, DUCK	CAT, DOG, DUCK
Single object		Multiple objects	

https://medium.com/zylapp/review-of-deep-learning-algorithms-for-object-detection-c1f3d437b852

示例：垃圾邮件过滤

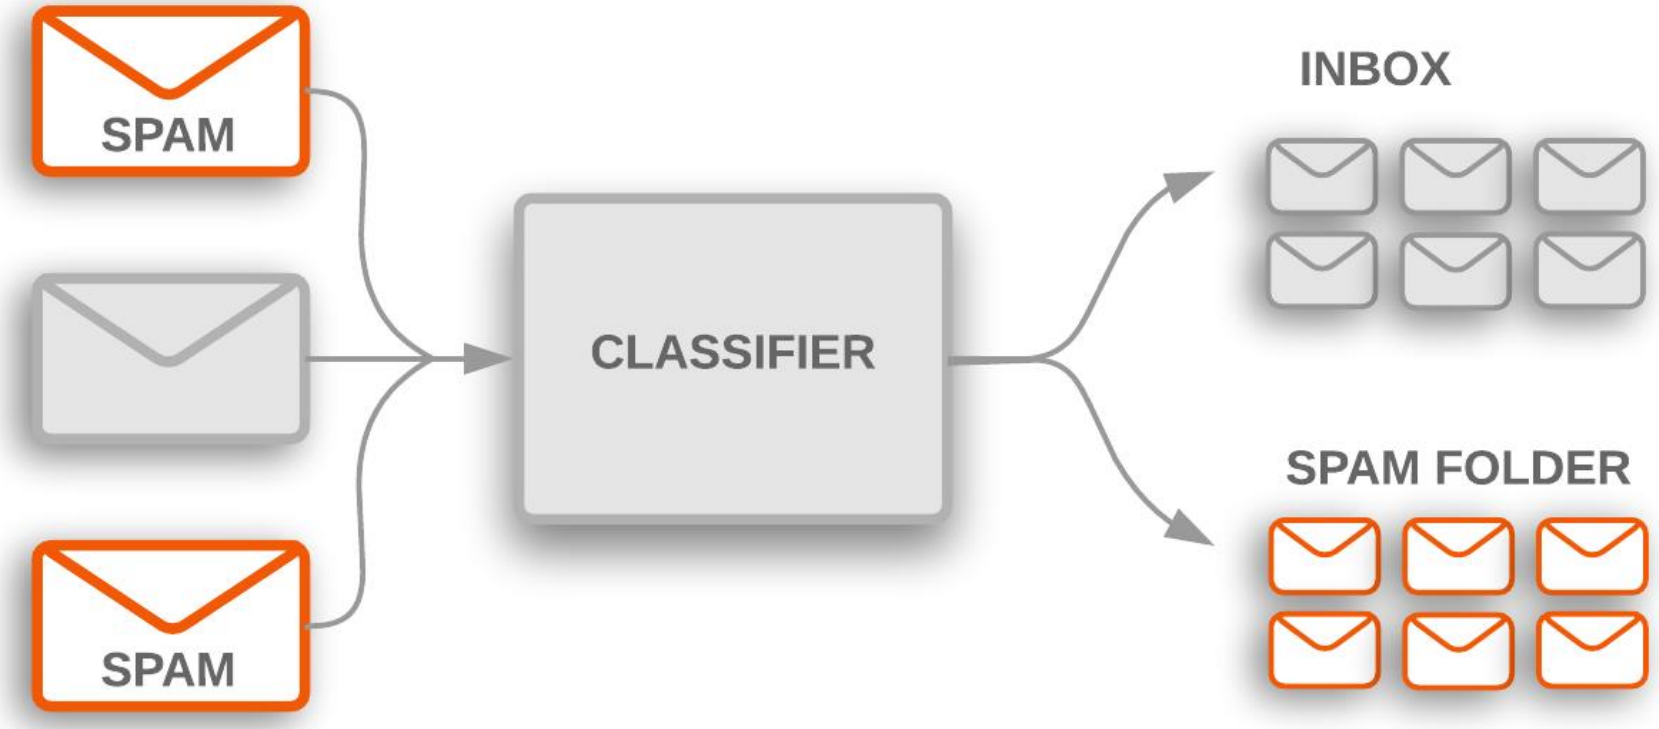

示例：文档归类

https://towardsdatascience.com/automated-text-classification-using-machine-learning-3df4f4f9570b

示例：情感分类

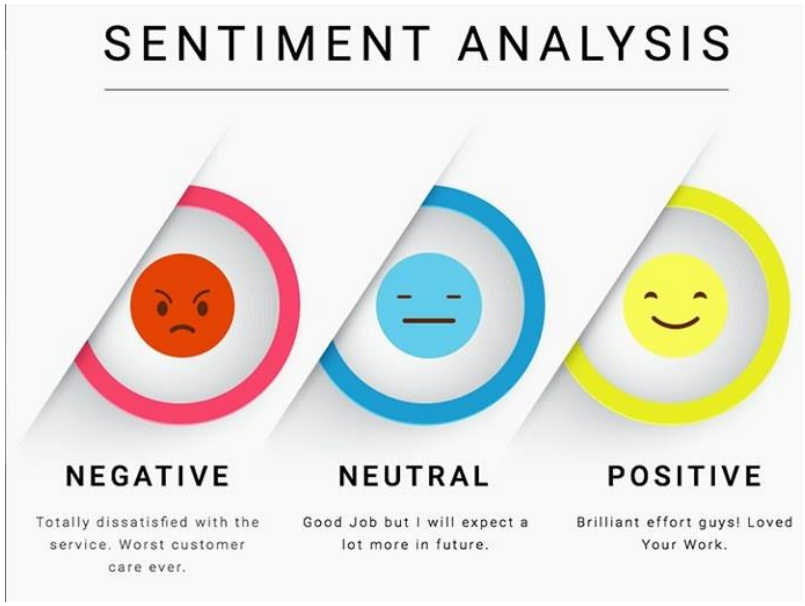

Review (X)	Rating (Y)
"This movie is fantastic! I really like it because it is so good!"	★★★★☆
"Not to my taste, will skip and watch another movie"	★★☆☆☆
"This movie really sucks! Can I get my money back please?"	★☆☆☆☆

示例：文本分类

将样本 X 从文本形式转为向量形式

词袋模型（Bag-of-Words，BoW）模型

比如两个文本“我 喜欢 读书”和“我 讨厌 读书”中共有“我”、“喜欢”、“讨厌”、“读书”四个词，它们的BoW表示分别为

$$\mathbf{v}_1 = [1\ 1\ 0\ 1\ ]^{\mathrm{T}},$$

$$\mathbf{v}_2 = [1\ 0\ 1\ 1\ ]^{\mathrm{T}}.$$

线性分类模型概述

线性模型

线性回归模型

$$f(\boldsymbol{x};\boldsymbol{w},b)=\boldsymbol{w}^{\top}\boldsymbol{x}+b,$$

线性分类模型

$$g(f(\boldsymbol{x};\boldsymbol{w}))=\begin{cases}1 & \text{if} \quad f(\boldsymbol{x};\boldsymbol{w})>0\\ 0 & \text{if} \quad f(\boldsymbol{x};\boldsymbol{w})<0\end{cases}$$

决策函数

判别函数

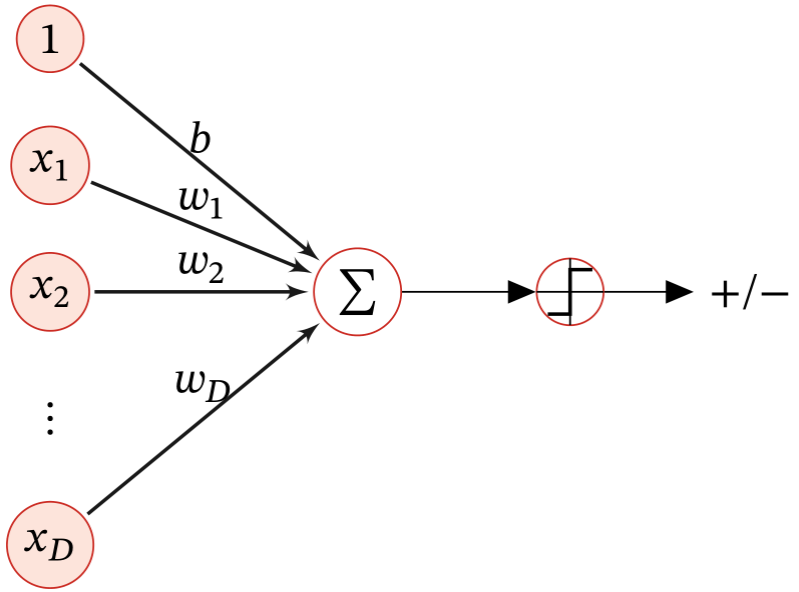

线性模型

线性分类模型

$$g(f(\boldsymbol{x};\boldsymbol{w})) = \begin{cases} 1 & \text{if} \quad f(\boldsymbol{x};\boldsymbol{w}) > 0 \\ 0 & \text{if} \quad f(\boldsymbol{x};\boldsymbol{w}) < 0 \end{cases}$$

线性分类模型=线性判别函数+线性决策边界

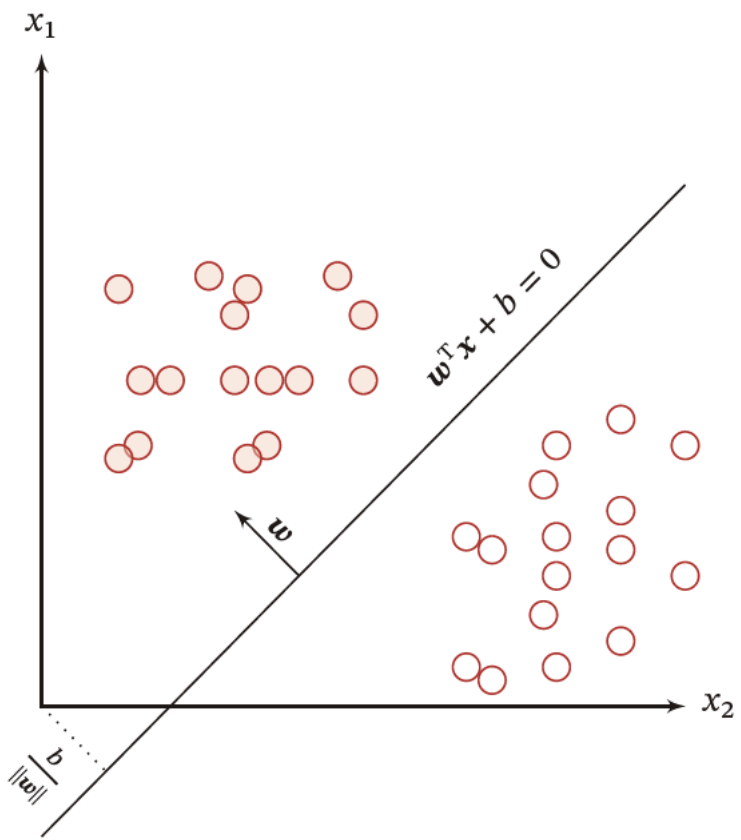

决策边界

二分类

训练集 $\mathcal{D} = \{(\boldsymbol{x}^{(n)}, y^{(n)})\}_{n=1}^{N}$

二分类问题 $\boldsymbol{x}^{(n)} \in \mathbb{R}^D$

$y^{(n)} \in \{+1, -1\}$

模型 $$g(f(\boldsymbol{x}; \boldsymbol{w})) = \begin{cases} 1 & \text{if} \quad f(\boldsymbol{x}; \boldsymbol{w}) > 0 \\ -1 & \text{if} \quad f(\boldsymbol{x}; \boldsymbol{w}) < 0 \end{cases}$$

损失函数?

0-1损失函数 $\mathcal{L}_{01}(y, f(\boldsymbol{x}; \boldsymbol{w})) = I(yf(\boldsymbol{x}; \boldsymbol{w}) < 0),$

多分类

训练集 $\mathcal{D} = \{(\boldsymbol{x}^{(n)}, y^{(n)})\}_{n=1}^{N}$

二分类问题 $\boldsymbol{x}^{(n)} \in \mathbb{R}^{D}$

$y^{(n)} \in \{1, \cdots, C\}$

模型

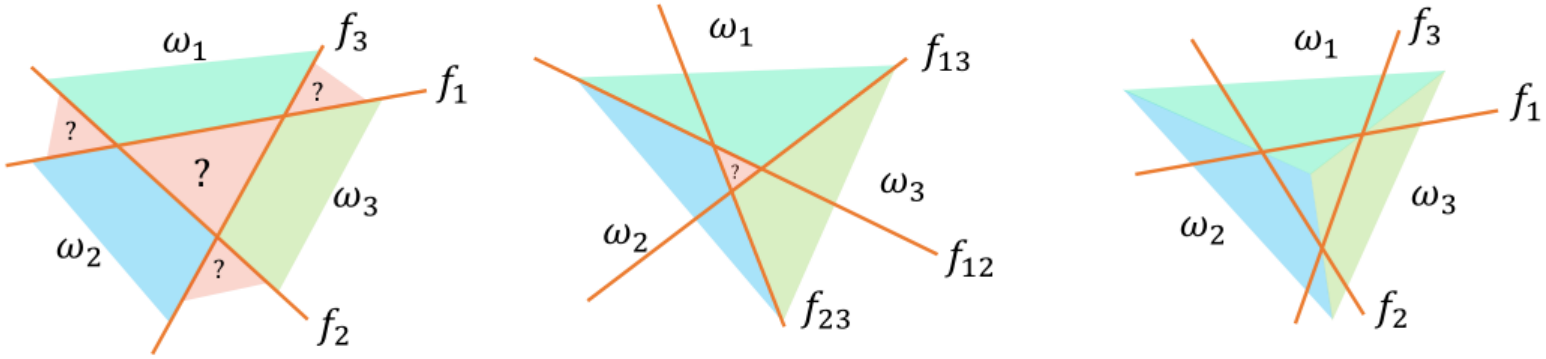

(a) “一对其余”方式 (b) “一对一”方式 (c) “argmax”方式

“argmax” 方式

一种改进的“一对其余”方式，共需要 C 个判别函数

$$f_c(\boldsymbol{x};\boldsymbol{w}_c) = \boldsymbol{w}_c^{\mathsf{T}}\boldsymbol{x} + b_c, \qquad c \in \{1, \cdots, C\}$$

“argmax” 方式判别函数定义为

$$y = \arg\max_{c=1}^{C} f_c(\boldsymbol{x};\boldsymbol{w}_c).$$

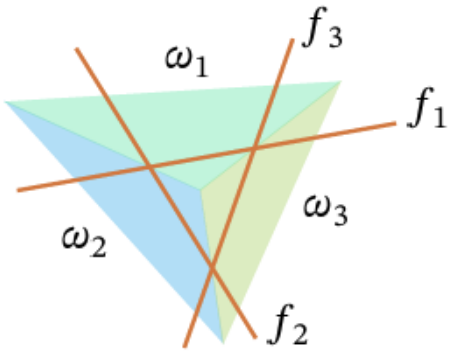

(c) “argmax”方式

分类问题的评价指标

样本集 $\{(\boldsymbol{x}^{(i)}, y^{(i)})\}_{i=1}^{n}$ 预测值 $\hat{y}^{(i)}$

准确率 (Accuracy)，所有预测正确的样本占总样本的比例

$$\text{Accuracy} = \frac{1}{N}\sum_{n=1}^{N}\mathbb{I}(y^{(n)} = \hat{y}^{(n)})$$

错误率 (Error Rate)， 分类错误的样本比例

$$\text{Error Rate} = \frac{1}{N}\sum_{n=1}^{N}\mathbb{I}(y^{(n)} \neq \hat{y}^{(n)}) = 1 - \text{Accuracy}$$

分类问题的评价指标

混淆矩阵 (Confusion Matrix)

	预测为正类 ($\hat{y}=1$)	预测为负类 ($\hat{y}=0$)
真实为正类 ($y=1$)	真正例 (True Positive, TP)	假负例 (False Negative, FN)
真实为负类 ($y=0$)	假正例 (False Positive, FP)	真负例 (True Negative, TN)

精确率 (Precision)，在所有被模型预测为“正类”的样本中，真实确实为“正类”的比例

$$\frac{TP}{TP+FP}$$

误报代价高昂，垃圾邮件识别

召回率 (Recall), 在所有“真实正类”样本中，被模型成功找出来的比例。

$$\frac{TP}{TP+FN}$$

漏报代价高昂，癌症识别

F_1-值：二者的调和平均

线性模型

- Logistic回归
- Softmax 回归
- 感知器
- 支持向量机

交叉熵与对数似然函数

以二分类问题为例

极大似然法求解分类问题

样本预测的条件概率（似然函数）

$$p(\boldsymbol{x}) = P(y = 1|\boldsymbol{x}; \boldsymbol{w})$$
$$p(y|\boldsymbol{x}) = p(\boldsymbol{x})^y \big(1 - p(\boldsymbol{x})\big)^{1-y}$$

样本集 $\{(\boldsymbol{x}^{(i)}, y^{(i)})\}_{i=1}^n$

联合条件概率分布 $\prod_{i=1}^{n} P(y^{(i)} \mid \boldsymbol{x}^{(i)}; \boldsymbol{w})$

取负对数似然

$$\mathcal{L}(\boldsymbol{w}) = -\sum_{i=1}^{n} \left[y^{(i)} \log p(\boldsymbol{x}^{(i)}) + (1 - y^{(i)}) \log(1 - p(\boldsymbol{x}^{(i)}))\right]$$

交叉熵

信息论

“信息”是指一组消息的集合

假设在一个噪声通道上发送消息，我们需要考虑如何对每一个信息进行编码、传输以及解码，使得接收者可以尽可能准确地重构出消息。

信息论将信息的传递看作一种统计现象

- 信息传输
- 信息压缩

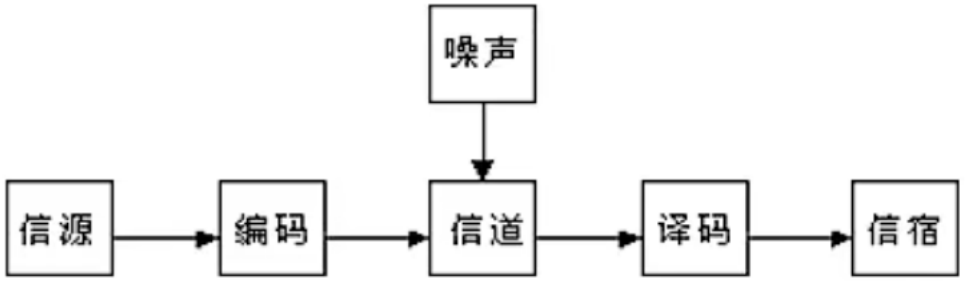

熵（Entropy）

在信息论中，熵用来衡量一个随机事件的不确定性

- 熵越高，则随机变量的信息越多
- 熵越低，则随机变量的信息越少

Applicatio_ Appl_

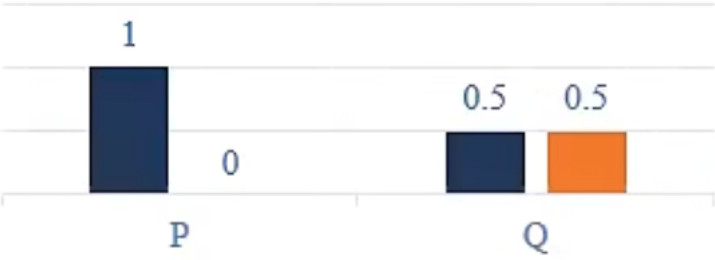

自信息：一个随机事件所包含的信息量

对于一个随机变量 X, 概率分布为 $p(x)$, 则$X = x$ 时自信息 $I(x)$ 定义为

$$I(x) = -\log p(x).$$

可加性

熵（Entropy）

熵: 随机变量 X 的自信息的数学期望

随机变量 X, 概率分布为 $p(x)$, 熵定义为

$$
\begin{aligned}
H(X) &= \mathbb{E}_X[I(x)] \\
&= \mathbb{E}_X[-\log p(x)] \\
&= -\sum_{x \in \mathcal{X}} p(x) \log p(x),
\end{aligned}
$$

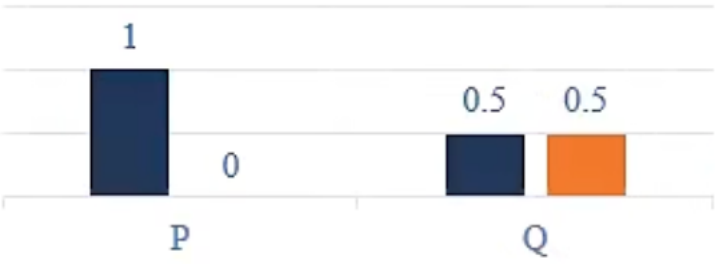

$$H(P) = 0$$

$$H(Q) = -\log 0.5$$

“描述一个随机变量结果之前，我们平均需要付出的信息量”

熵编码

在对分布 $p(x)$的符号进行编码时，熵 $H(p)$ 也是理论上最优的平均编码长度，这种编码方式称为熵编码

交叉熵（Cross Entropy）

交叉熵是按照概率分布 q 的最优编码对真实分布为 p 的信息进行编码的长度

$$
\begin{aligned}
H(p,q) &= \mathbb{E}_p[-\log q(x)] \\
&= -\sum_x p(x)\log q(x).
\end{aligned}
$$

- 在给定 q 的情况下, 如果 p 和 q 越接近，交叉熵越小
- 如果 p 和 q 越远, 交叉熵就越大

“当真实数据来自分布 p，但我们却用分布 q来编码时，平均需要付出的信息量。”

KL散度（Kullback-Leibler Divergence）

KL散度是用概率分布 q 来近似 p 时所造成的信息损失量

KL散度是按照概率分布 q 的最优编码对真实分布为 p 的信息进行编码，其平均编码长度（即交叉熵） $H(p,q)$ 和为 p 的最优平均编码长度（即熵） $H(p)$ 之间的差异

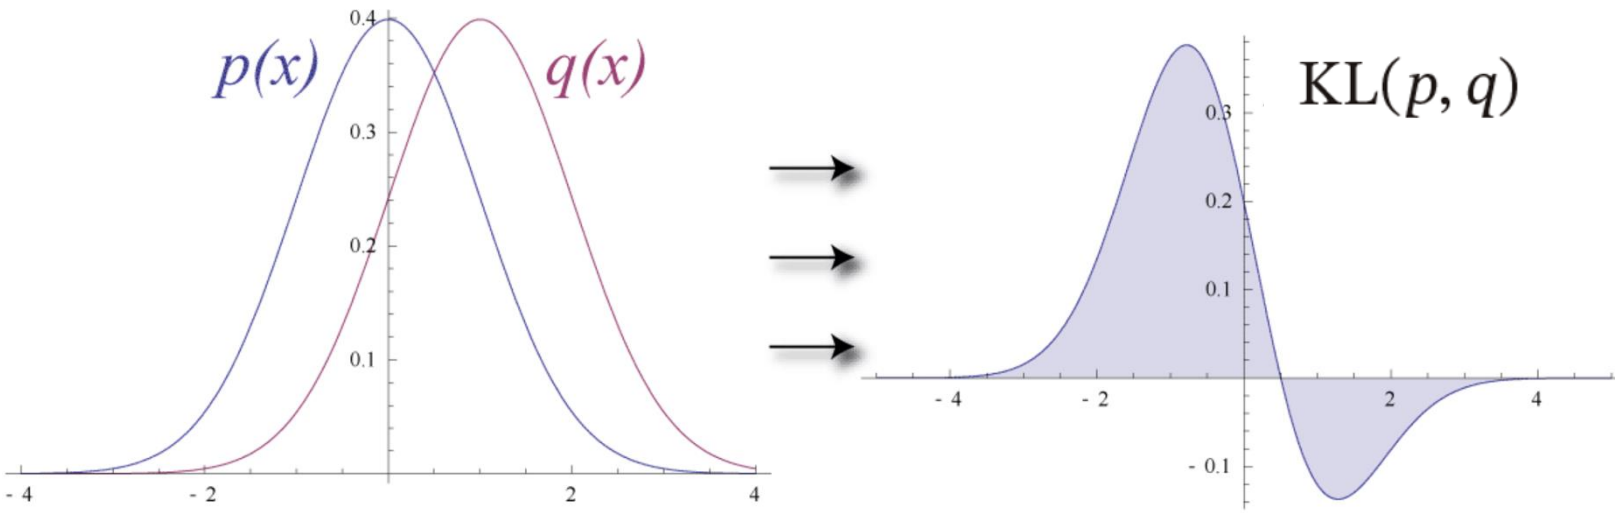

$$\mathrm{KL}(p,q) = H(p,q) - H(p)$$
$$= \sum_x p(x) \log \frac{p(x)}{q(x)}$$

$$\mathrm{KL}(p,q) \geq 0.$$

应用到机器学习

以分类为例

真实分布: $p_r(y|\boldsymbol{x})$

预测分布: $p_\theta(y|\boldsymbol{x})$

设 y^* 为 $\boldsymbol{x}$ 的真实标签

$$p_r(y^*|\boldsymbol{x}) = 1$$

$$p_r(y|\boldsymbol{x}) = 0, \qquad \forall\, y \neq y^*$$

如何衡量两个分布的差异？

$$\mathrm{KL}(p_r(y|\boldsymbol{x}), p_\theta(y|\boldsymbol{x})) = \sum_y p_r(y|\boldsymbol{x}) \log \frac{p_r(y|\boldsymbol{x})}{p_\theta(y|\boldsymbol{x})}$$

KL散度定义

$$\propto -\sum_y p_r(y|\boldsymbol{x}) \log p_\theta(y|\boldsymbol{x})$$

交叉熵损失

$$= -\log p_\theta(y^*|\boldsymbol{x})$$

负对数似然

Logistic 回归

线性模型

线性分类模型

$$f(\boldsymbol{x};\boldsymbol{w},b)=\boldsymbol{w}^{\top}\boldsymbol{x}+b,$$

$$g(f(\boldsymbol{x};\boldsymbol{w}))=\begin{cases}1 & \text{if} \quad f(\boldsymbol{x};\boldsymbol{w})>0\\ 0 & \text{if} \quad f(\boldsymbol{x};\boldsymbol{w})<0\end{cases}$$

线性分类模型=线性判别函数+线性决策边界

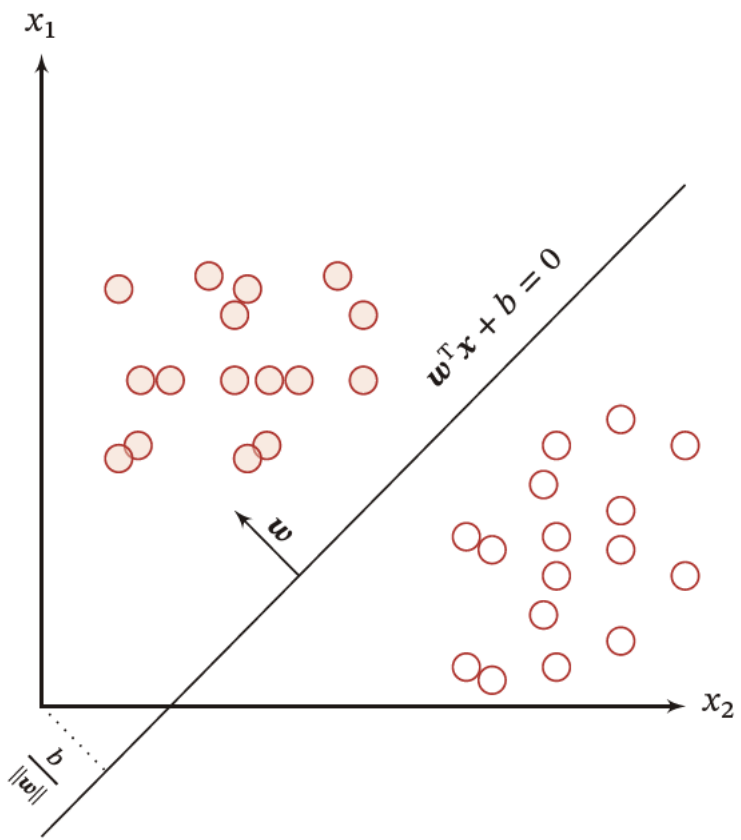

决策边界

Logistic 回归

也称为对数几率回归

$$g(f(\boldsymbol{x};\boldsymbol{w})) = \begin{cases} 1 & \text{if} \quad f(\boldsymbol{x};\boldsymbol{w}) > 0 \\ 0 & \text{if} \quad f(\boldsymbol{x};\boldsymbol{w}) < 0 \end{cases}$$

损失函数？

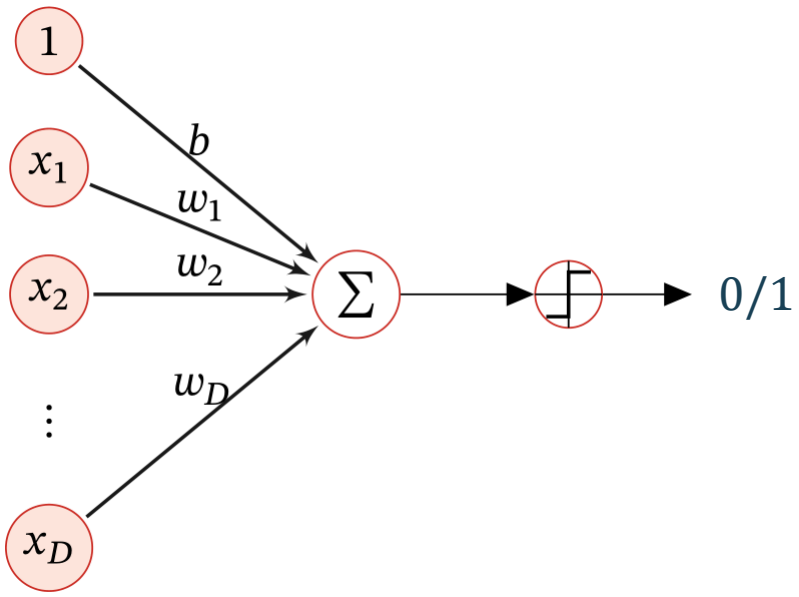

分类问题

将分类问题看作条件概率估计问题

引入非线性函数 g 来预测类别标签的条件概率 $p(y=c|x)$

以二分类为例

$$p(y=1|\mathbf{x})=g(f(\mathbf{x};\mathbf{w}))$$

函数 f: 线性函数

函数 g : 把线性函数的值域从实数区间“挤压”到了(0,1)之间，可以用来表示概率

如何构建函数g?

Logistic函数与回归

Logistic 函数

$$\sigma(x) = \frac{1}{1 + \exp(-x)}$$

除了logisitc，还有什么函数$f: R \to (0,1)$?

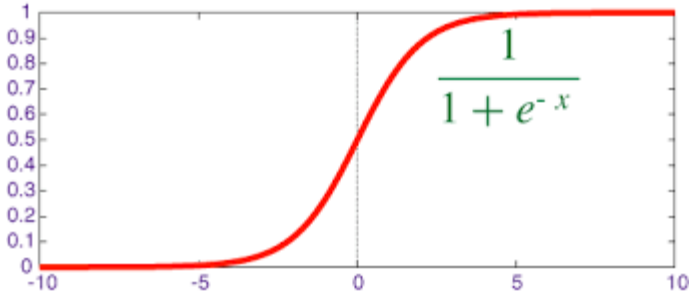

Logistic 回归

$$p(y = 1|\boldsymbol{x}) = \sigma(\boldsymbol{w}^\top \boldsymbol{x})$$
$$\triangleq \frac{1}{1 + \exp(-\boldsymbol{w}^\top \boldsymbol{x})}$$

学习准则

模型预测条件概率 $p_\theta(y|\boldsymbol{x})$

$$p_\theta(y=1|\boldsymbol{x}) = \sigma(\boldsymbol{w}^T\boldsymbol{x})$$

真实条件概率 $p_r(y|\boldsymbol{x})$

对于一个样本 (x, y^*), 其真实条件概率为

$$p_r(y=1|\boldsymbol{x}) = y^*$$
$$p_r(y=0|\boldsymbol{x}) = 1 - y^*$$

$$H(p,q) = \mathbb{E}_p[-\log q(x)]$$
$$= -\sum_x p(x)\log q(x).$$

如何衡量两个条件分布的差异？

$$H(p_r, p_\theta) = -(y^*\log\hat{y} + (1-y^*)\log 1-\hat{y})$$

$$\hat{y} = p_\theta(y=1|\boldsymbol{x})$$

梯度下降

交叉熵损失函数，模型在训练集的风险函数为

$$\mathcal{R}(\boldsymbol{w}) = -\frac{1}{N}\sum_{n=1}^{N}\left(y^{(n)}\log\hat{y}^{(n)} + (1-y^{(n)})\log(1-\hat{y}^{(n)})\right)$$

梯度为

$$\begin{aligned}\frac{\partial\mathcal{R}(\boldsymbol{w})}{\partial\boldsymbol{w}} &= -\frac{1}{N}\sum_{n=1}^{N}\left(y^{(n)}\frac{\hat{y}^{(n)}(1-\hat{y}^{(n)})}{\hat{y}^{(n)}}\boldsymbol{x}^{(n)} - (1-y^{(n)})\frac{\hat{y}^{(n)}(1-\hat{y}^{(n)})}{1-\hat{y}^{(n)}}\boldsymbol{x}^{(n)}\right)\\ &= -\frac{1}{N}\sum_{n=1}^{N}\left(y^{(n)}(1-\hat{y}^{(n)})\boldsymbol{x}^{(n)} - (1-y^{(n)})\hat{y}^{(n)}\boldsymbol{x}^{(n)}\right)\\ &= -\frac{1}{N}\sum_{n=1}^{N}\boldsymbol{x}^{(n)}(y^{(n)}-\hat{y}^{(n)}).\end{aligned}$$

迭代更新

$$\boldsymbol{w}_{t+1} \leftarrow \boldsymbol{w}_t + \alpha\frac{1}{N}\sum_{n=1}^{N}\boldsymbol{x}^{(n)}\left(y^{(n)} - \hat{y}_{\boldsymbol{w}_t}^{(n)}\right)$$

Logistic回归

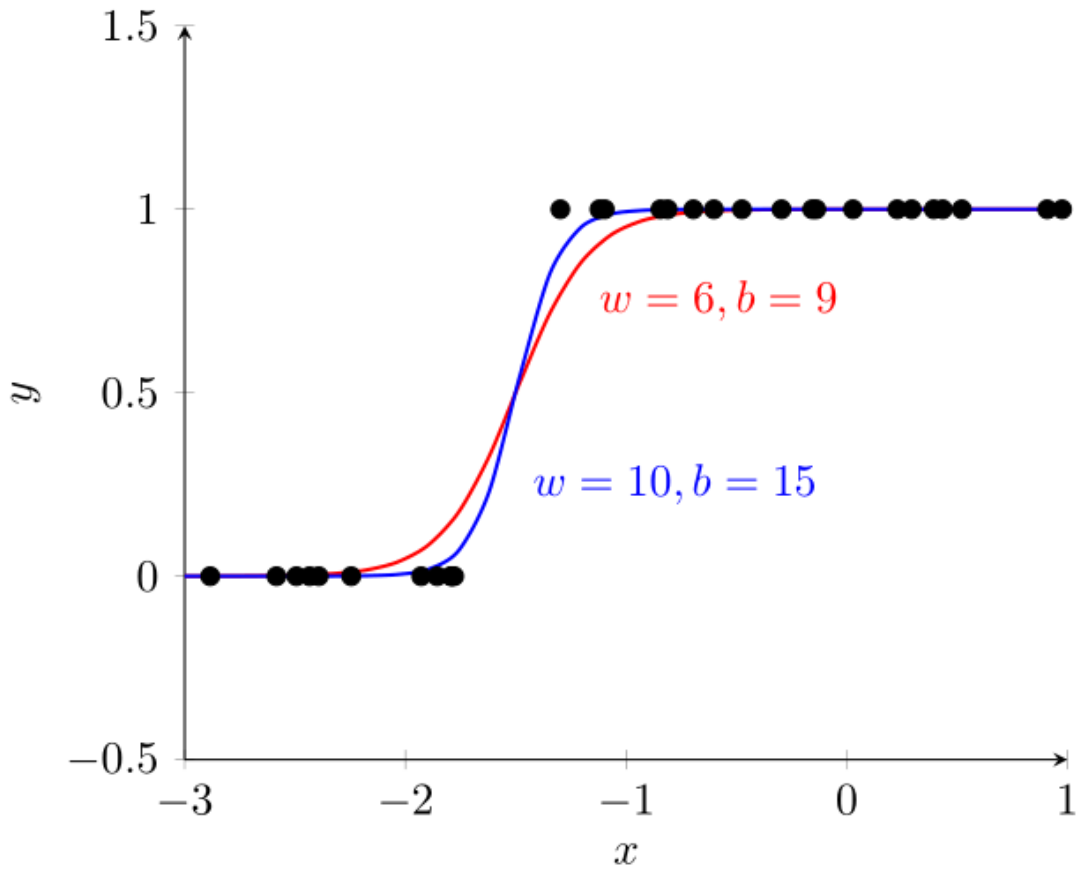

Softmax 回归

Softmax 回归

多分类问题

对于多类问题，类别 $y \in \{1, 2, \cdots, C\}$ 可以有 C 个取值

模型

$$y = \arg\max_{c=1}^{C} f_c(\boldsymbol{x}; \boldsymbol{w}_c)$$

$$f_c(\boldsymbol{x}; \boldsymbol{w}_c) = \boldsymbol{w}_c^{\mathrm{T}} \boldsymbol{x} + b_c, \qquad c \in \{1, \cdots, C\}$$

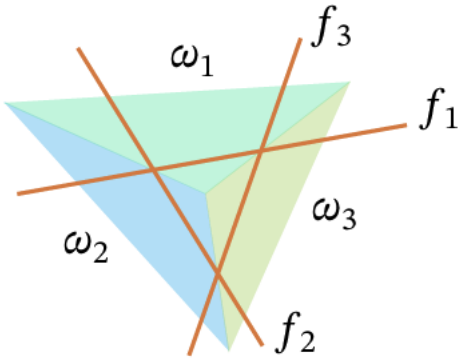

(c) “argmax”方式

学习准则

转化为条件概率建模 $p_\theta(y = \mathrm{c}|\boldsymbol{x})$

Softmax 函数

已知 $f_c(\boldsymbol{x};\boldsymbol{w}_c) = \boldsymbol{w}_c^{\mathrm{T}}\boldsymbol{x} + b_c, \qquad c \in \{1, \cdots, C\}$

建模 $p_\theta(y = \mathrm{c}|\boldsymbol{x})$

Softmax 函数

对于 C 个标量 $x_1, \cdots, x_C$

$$\mathrm{softmax}\,(x_c) = \frac{\exp\,(x_c)}{\sum_{i=1}^{C} \exp\,(x_i)}$$

Softmax 回归

利用 Softmax 函数，目标类别 $y = c$ 的条件概率为：

$$
\begin{aligned}
p(y = c|\boldsymbol{x}) &= \mathrm{softmax}(\boldsymbol{w}_c^\top \boldsymbol{x}) \\
&= \frac{\exp(\boldsymbol{w}_c^\top \boldsymbol{x})}{\sum_{c'=1}^{C} \exp(\boldsymbol{w}_{c'}^\top \boldsymbol{x})},
\end{aligned}
$$

向量表示

$$
\begin{aligned}
\hat{\boldsymbol{y}} &= \mathrm{softmax}(\boldsymbol{W}^\top \boldsymbol{x}) \\
&= \frac{\exp(\boldsymbol{W}^\top \boldsymbol{x})}{\mathbf{1}_C^\top \exp(\boldsymbol{W}^\top \boldsymbol{x})},
\end{aligned}
$$

$\hat{\boldsymbol{y}} \in \mathbb{R}^C$ 为所有类别的预测条件概率组成的向量

交叉熵损失

$$-\sum_{y=1}^{C} p_r(y|\boldsymbol{x}) \log p_\theta(y|\boldsymbol{x})$$

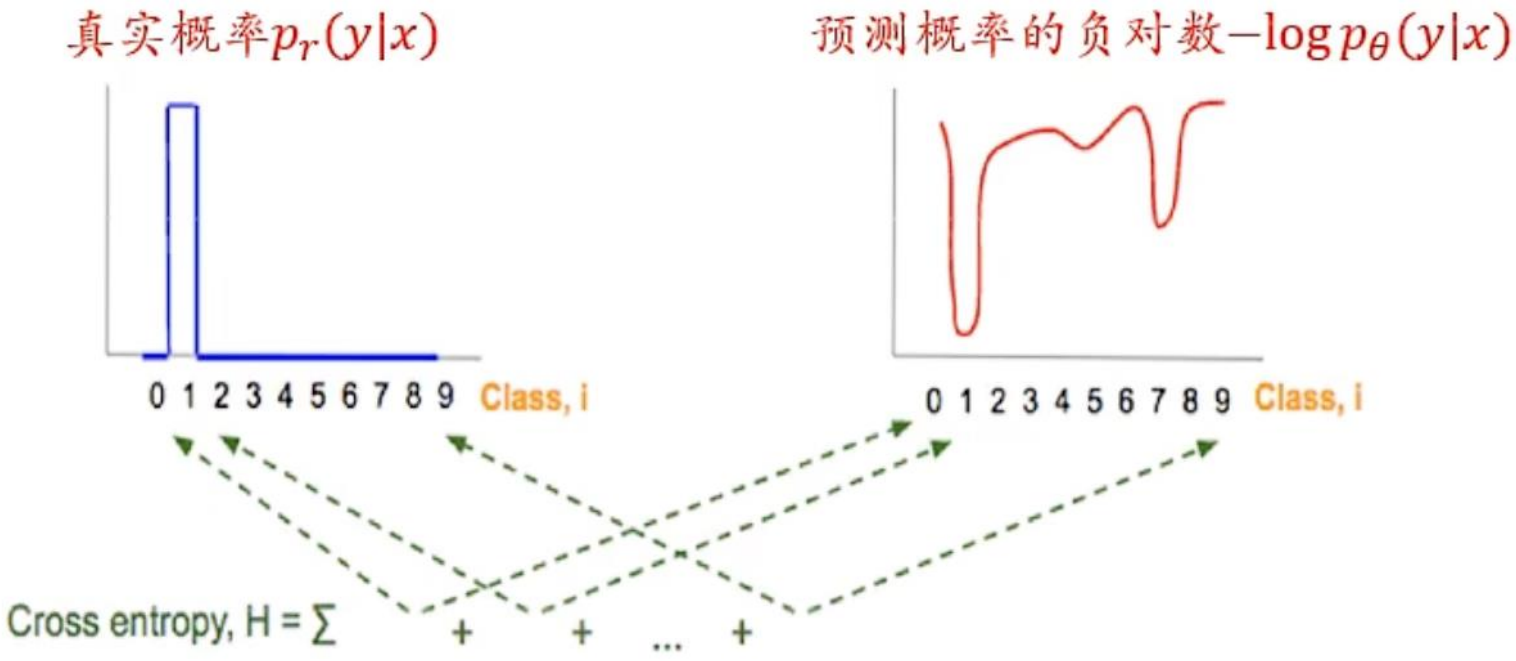

交叉熵损失函数

向量形式

$$-\boldsymbol{y}^\top \log \hat{\boldsymbol{y}} \qquad \boldsymbol{y} = [I(1=c), I(2=c), \cdots, I(C=c)]^\top,$$

对于一个三类分类问题，类别为 [0,0,1]，预测类别概率为 [0.3,0.3,0.4]，则

$$\begin{aligned}\mathcal{L}(\theta) &= -\big(0 \times \log(0.3) + 0 \times \log(0.3) + 1 \times \log(0.4)\big) \\ &= -\log(0.4).\end{aligned}$$

负对数似然损失函数

参数学习

学习准则：交叉熵

$$\mathcal{R}(\boldsymbol{W}) = -\frac{1}{N}\sum_{n=1}^{N}(\boldsymbol{y}^{(n)})^{\mathsf{T}}\log\hat{\boldsymbol{y}}^{(n)}$$

$$\boldsymbol{y} = [I(1=c), I(2=c), \cdots, I(C=c)]^{\mathsf{T}},$$

优化：梯度下降

$$\frac{\partial\mathcal{R}(\boldsymbol{W})}{\partial\boldsymbol{W}} = -\frac{1}{N}\sum_{n=1}^{N}\boldsymbol{x}^{(n)}\left(\boldsymbol{y}^{(n)} - \hat{\boldsymbol{y}}^{(n)}\right)^{\mathsf{T}}$$

与 Logistic 回归的关系?

感知机

感知器

Psychological Review
Vol. 65, No. 6, 1958

THE PERCEPTRON: A PROBABILISTIC MODEL FOR INFORMATION STORAGE AND ORGANIZATION IN THE BRAIN[1]

F. ROSENBLATT

Cornell Aeronautical Laboratory

HAVING told you about the giant digital computer known as I.B.M. 704 and how it has been taught to play a fairly creditable game of chess, we'd like to tell you about an even more remarkable machine, the perceptron, which, as its name implies, is capable of what amounts to original thought. The first perceptron has yet to be built,

The New Yorker, December 6, 1958 P. 44

The IBM 704 computer

感知器

模型

模拟生物神经元行为的机器，有与生物神经元相对应的部件，如权重（突触）、偏置（阈值）及激活函数（细胞体），输出为+1或-1。

$$\hat{y} = \mathrm{sgn}(\boldsymbol{w}^\top \boldsymbol{x}).$$

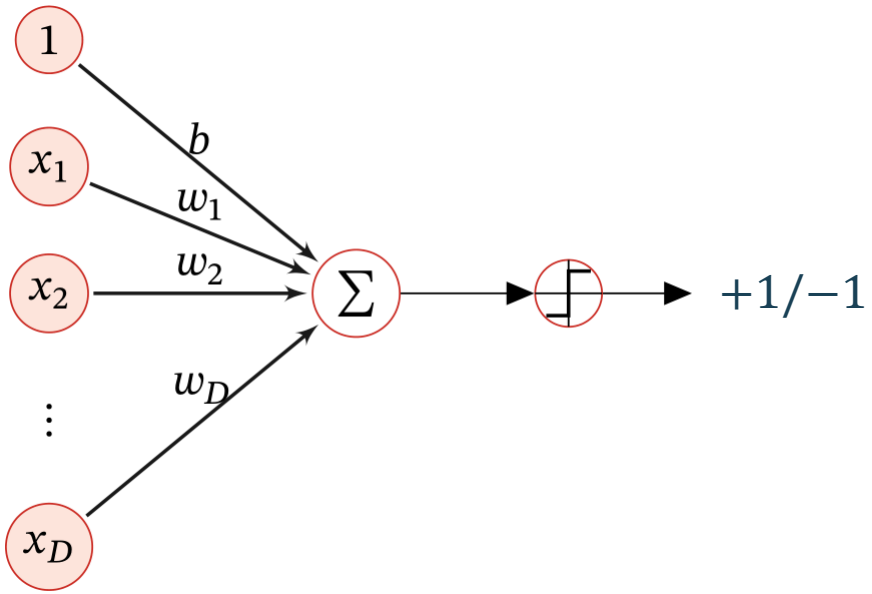

学习目标

训练集 $\mathcal{D} = \{(\boldsymbol{x}^{(n)}, y^{(n)})\}_{n=1}^{N}$

找到权重 $\boldsymbol{w}^*$ 使得

$$y^{(n)} \boldsymbol{w}^{*\top} \boldsymbol{x}^{(n)} > 0, \qquad \forall n \in \{1, \cdots, N\}.$$

优化方法

一种错误驱动的在线学习算法

学习算法

一种错误驱动的在线学习算法

先初始化一个权重向量$\boldsymbol{w} \leftarrow 0$（通常是全零向量）

每次分错一个样本$(\boldsymbol{x}, y)$时，即

$$y\boldsymbol{w}^T\boldsymbol{x} \leq \mathbf{0}$$

用这个样本来更新权重

$$\boldsymbol{w} \leftarrow \boldsymbol{w} + y\boldsymbol{x}$$

损失函数

$$\mathcal{L}(\boldsymbol{w}; \boldsymbol{x}, y) = \max(0, -y\boldsymbol{w}^{\top}\boldsymbol{x}).$$

感知器的学习过程

算法 3.1　两类感知器的参数学习算法

输入: 训练集 $\mathcal{D} = \{(\boldsymbol{x}^{(n)}, y^{(n)})\}_{n=1}^{N}$，最大迭代次数 T

```
初始化: w_0 ← 0, k ← 0, t ← 0;
repeat
    对训练集 D 中的样本随机排序;
    for n = 1 ··· N do
        选取一个样本 (x^(n), y^(n));
        if w_k^T (y^(n) x^(n)) ≤ 0 then        表示分错
            w_{k+1} ← w_k + y^(n) x^(n);
            k ← k + 1;
        end
        t ← t + 1;
        if t = T then break;                    // 达到最大迭代次数
    end
until t = T;
输出: w_k
```

对比 Logistic 回归的更新方式

$$\boldsymbol{w}_{t+1} \leftarrow \boldsymbol{w}_t + \alpha \frac{1}{N} \sum_{n=1}^{N} \boldsymbol{x}^{(n)} \left(y^{(n)} - \hat{y}_{\boldsymbol{w}_t}^{(n)} \right)$$

感知器参数学习的更新过程

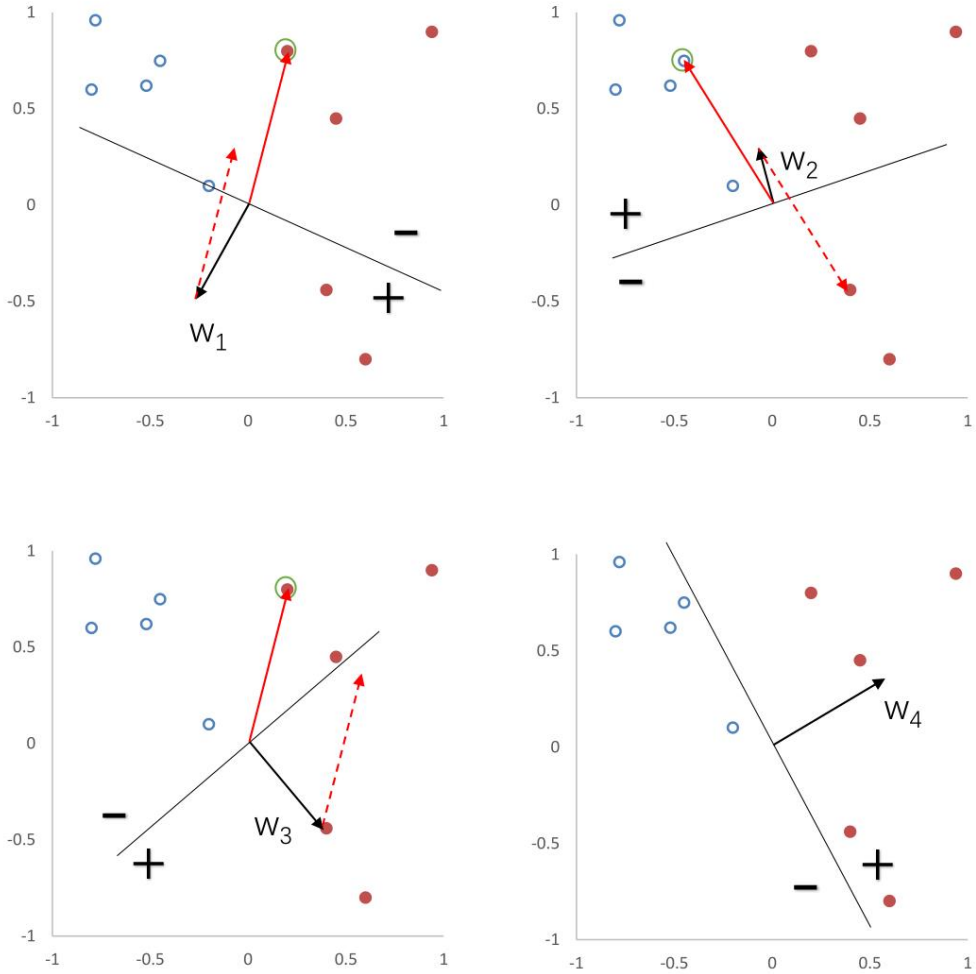

收敛性

定理 3.1 – 感知器收敛性：给定训练集 $\mathcal{D} = \{(\boldsymbol{x}^{(n)}, y^{(n)})\}_{n=1}^{N}$，令 R 是训练集中最大的特征向量的模，即

$$R = \max_{n} \|x^{(n)}\|.$$

如果训练集 $\mathcal{D}$ 线性可分，两类感知器的参数学习算法3.1的权重更新次数不超过 $\frac{R^2}{\gamma^2}$.

权重向量 $\boldsymbol{w}^*$ 满足 $|\boldsymbol{w}|^* = 1$, 常数 $\gamma > 0$ 对所有 n 都满足 $(\boldsymbol{w}^*)^{\mathsf{T}}(y^{(n)}\boldsymbol{x}^{(n)}) \geq \gamma$.

证明过程

感知器的权重向量的更新方式为

$$\boldsymbol{w}_k = \boldsymbol{w}_{k-1} + y^{(k)}\boldsymbol{x}^{(k)}$$

在第 K 次更新时感知器的权重向量为

$$\boldsymbol{w}_K = \sum_{k=1}^{K} y^{(k)}\boldsymbol{x}^{(k)}$$

$\|\boldsymbol{w}_K\|^2$ 的上界 KR^2

$\|\boldsymbol{w}_K\|^2$ 的下界 $K^2\gamma^2$.

支持向量机

线性分类

以二分类为例

判别函数

$$f(\boldsymbol{x};\boldsymbol{w},b)=\boldsymbol{w}^{\top}\boldsymbol{x}+b,$$

通过决策函数来进行决策

假设训练数据是线性可分的

以感知器为例，我们可以获得很多“好的”分类器

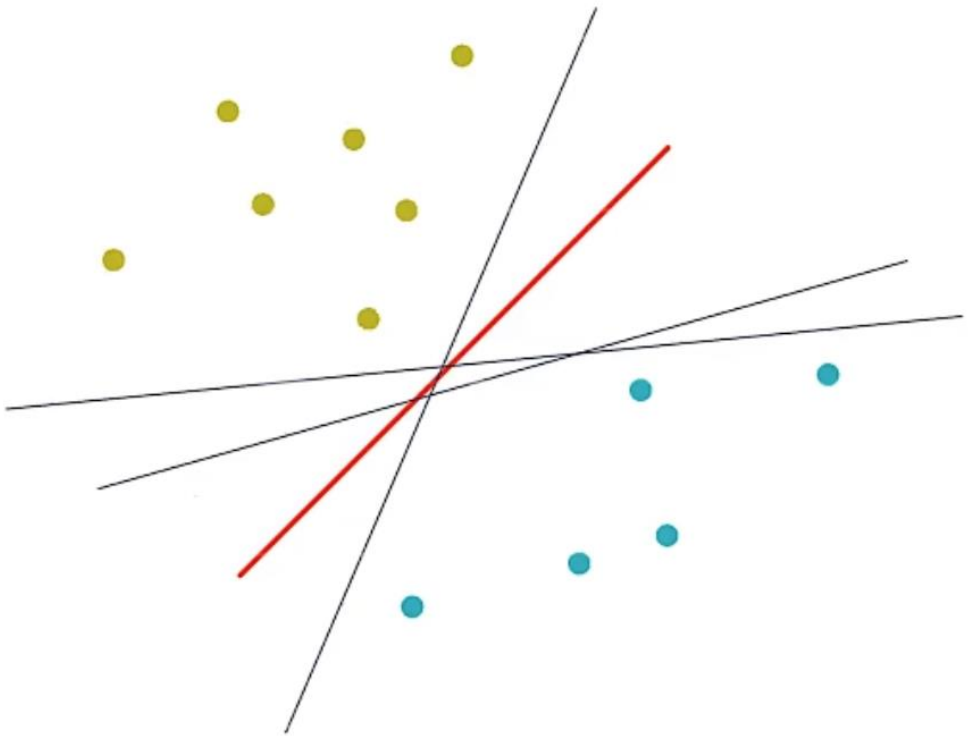

哪个分类器更好?

最大间隔

间隔 Margin

决策边界到分类样本的最短距离

支持向量机 Support Vector Machine

选择间隔最大的决策边界

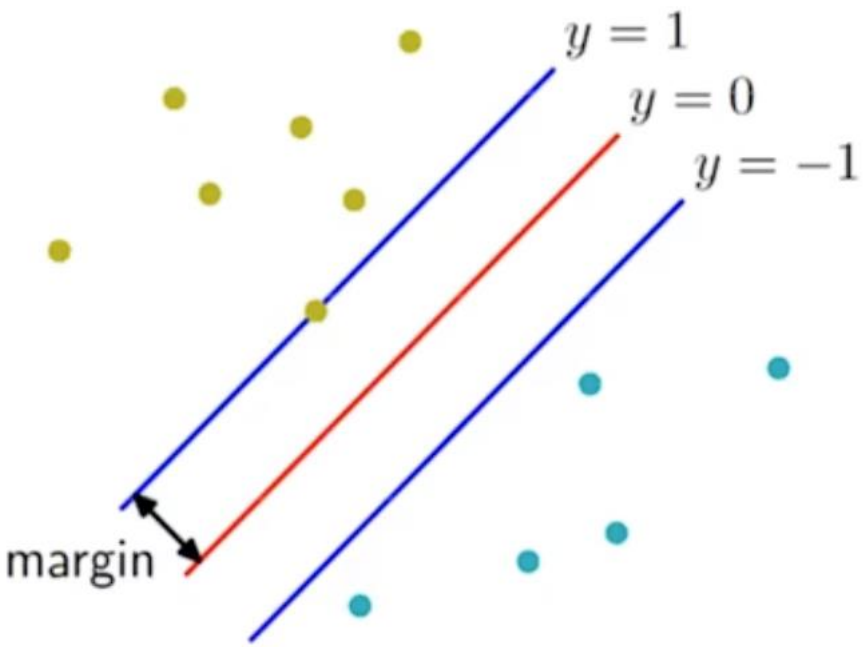

几何知识

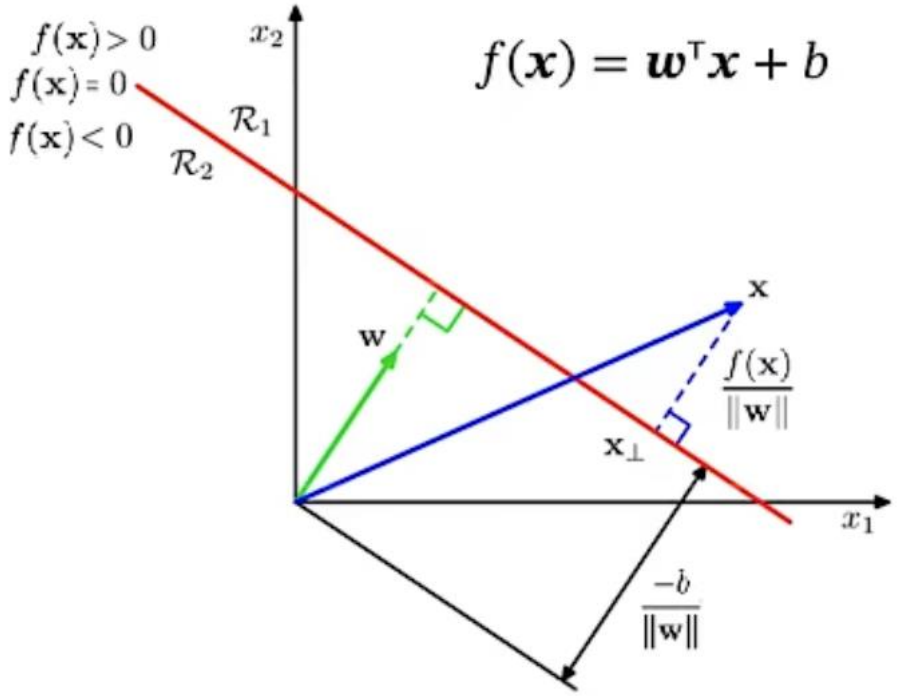

点 $\boldsymbol{x}$ 到 $\boldsymbol{w}$ 方向上的投影: $\dfrac{\boldsymbol{w}^\top \boldsymbol{x}}{|\boldsymbol{w}|}$

$f(\boldsymbol{x}) = 0$ 上的点到 $\boldsymbol{w}$ 方向上的投影:

$$\frac{\boldsymbol{w}^\top \boldsymbol{x}}{|\boldsymbol{w}|} = \frac{-\boldsymbol{b}}{|\boldsymbol{w}|}$$

点 $\boldsymbol{x}$ 到超平面 $f(\boldsymbol{x}) = 0$的有向距离

$$d = \frac{\boldsymbol{w}^\top \boldsymbol{x}}{|\boldsymbol{w}|} - \frac{-\boldsymbol{b}}{|\boldsymbol{w}|} = \frac{f(\boldsymbol{x})}{|\boldsymbol{w}|}$$

假设超平面 $f(\boldsymbol{x}) = 0$可以将训练集的所有样本分开, 则对于训练样本 $(\boldsymbol{x}, y)$ 有

$$y(\boldsymbol{w}^\top \boldsymbol{x} + \boldsymbol{b}) > 0$$

训练样本 $(\boldsymbol{x}, y)$到超平面 $f(\boldsymbol{x}) = 0$的距离

$$\gamma = \frac{y f(\boldsymbol{x})}{|\boldsymbol{w}|} = \frac{y(\boldsymbol{w}^\top \boldsymbol{x} + \boldsymbol{b})}{|\boldsymbol{w}|}$$

支持向量机（Support Vector Machine，SVM）

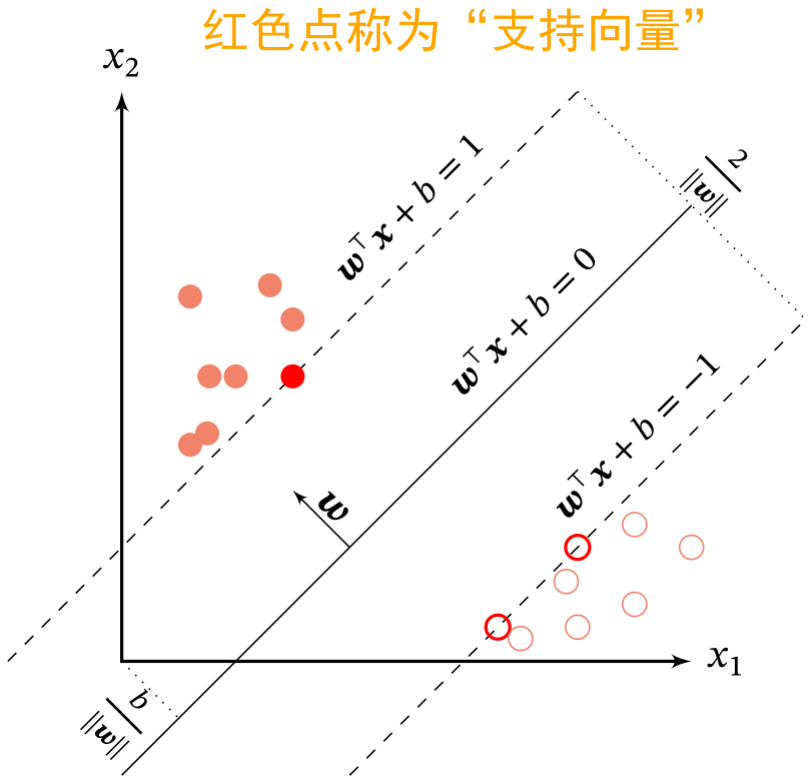

数据集 $\mathcal{D}$ 中每个样本 $\boldsymbol{x}^{(n)}$ 到分割超平面的距离为：

$$\gamma^{(n)} = \frac{\|\boldsymbol{w}^\top \boldsymbol{x}^{(n)} + b\|}{\|\boldsymbol{w}\|} = \frac{y^{(n)}(\boldsymbol{w}^\top \boldsymbol{x}^{(n)} + b)}{\|\boldsymbol{w}\|}.$$

支持向量机的目标是寻找一个超平面 $(\boldsymbol{w}^*, b^*)$ 使得 γ 最大，即

$$\begin{aligned} \max_{\boldsymbol{w},b} \quad & \gamma \\ \text{s.t.} \quad & \frac{y^{(n)}(\boldsymbol{w}^\top \boldsymbol{x}^{(n)} + b)}{\|\boldsymbol{w}\|} \geq \gamma, \forall n \in \{1, \cdots, N\} \end{aligned}$$

$\Downarrow$ 限制 $\|\boldsymbol{w}\| \cdot \gamma = 1$，

$$\begin{aligned} \max_{\boldsymbol{w},b} \quad & \frac{1}{\|\boldsymbol{w}\|^2} \\ \text{s.t.} \quad & y^{(n)}(\boldsymbol{w}^\top \boldsymbol{x}^{(n)} + b) \geq 1, \forall n \in \{1, \cdots, N\} \end{aligned}$$

软间隔

在支持向量机的优化问题中，如果训练集中的样本不是线性可分的，就无法找到最优解。

为了能够容忍部分不满足约束的样本，可以引入松弛变量

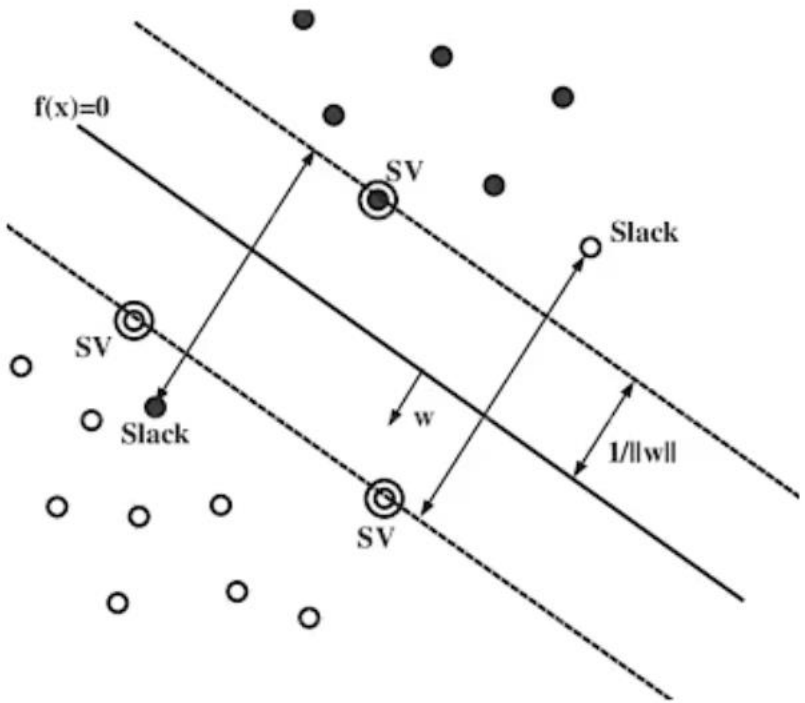

软间隔

$$\max_{\boldsymbol{w},b} \quad \frac{1}{\|\boldsymbol{w}\|^2}$$

$$\text{s.t.} \quad y^{(n)}(\boldsymbol{w}^\top \boldsymbol{x}^{(n)} + b) \geq 1, \forall n \in \{1, \cdots, N\}$$

$$\Downarrow$$

$$\min_{\boldsymbol{w},b} \quad \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{n=1}^{N} \xi_n$$

$$\text{s.t.} \quad 1 - y^{(n)}(\boldsymbol{w}^\top \boldsymbol{x}^{(n)} + b) - \xi_n \leq 0, \qquad \forall n \in \{1, \cdots, N\}$$

$$\xi_n \geq 0, \qquad \forall n \in \{1, \cdots, N\}$$

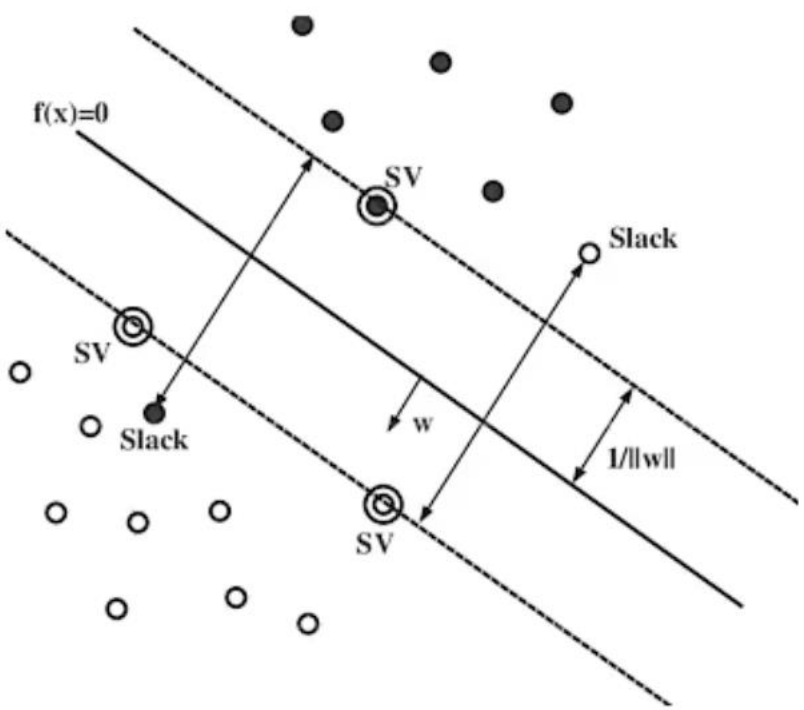

软间隔

$$\min_{\boldsymbol{w},b} \quad \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{n=1}^{N}\xi_n$$

$$\text{s.t.} \quad 1 - y^{(n)}(\boldsymbol{w}^{\top}\boldsymbol{x}^{(n)} + b) - \xi_n \le 0, \qquad \forall n \in \{1, \cdots, N\}$$

$$\xi_n \ge 0, \qquad \forall n \in \{1, \cdots, N\}$$

等价

$$\min_{\boldsymbol{w},b} \quad \underbrace{\sum_{n=1}^{N}\max\left(0, 1 - y^{(n)}(\boldsymbol{w}^{\top}\boldsymbol{x}^{(n)} + b)\right)}_{\text{经验风险}} + \underbrace{\frac{1}{2C}\|\boldsymbol{w}\|^2}_{\text{正则化项}}$$

Hinge 损失函数

$$\mathcal{L}(\boldsymbol{w}; \boldsymbol{x}, y) = \max(0, -y\boldsymbol{w}^{\top}\boldsymbol{x}).$$

感知器损失

不同损失函数的对比

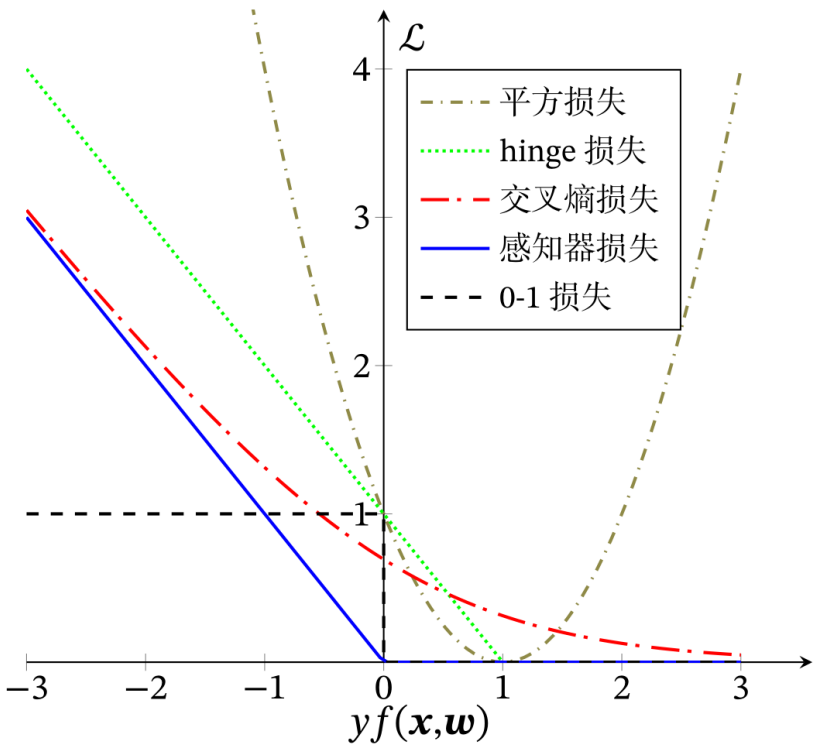

统一定义类别标签 $y \in \{+1, -1\}$

若 $yf(\boldsymbol{x}; \boldsymbol{w}) > 0$，则分类正确

平方损失函数可以重写为

$$\begin{aligned}\mathcal{L}_{squared} &= \big(y - f(\boldsymbol{x}; \boldsymbol{w})\big)^2 \\ &= 1 - 2yf(\boldsymbol{x}; \boldsymbol{w}) + (yf(\boldsymbol{x}; \boldsymbol{w}))^2 \\ &= \big(1 - yf(\boldsymbol{x}; \boldsymbol{w})\big)^2.\end{aligned}$$

Logistic 损失函数可以重写为

$$\begin{aligned}\mathcal{L}_{LR} &= -I(y=1)\log\sigma\big(f(\boldsymbol{x}; \boldsymbol{w})\big) - I(y=-1)\log\Big(1 - \sigma\big(f(\boldsymbol{x}; \boldsymbol{w})\big)\Big) \\ &= -I(y=1)\log\sigma\big(f(\boldsymbol{x}; \boldsymbol{w})\big) - I(y=-1)\log\sigma\big(-f(\boldsymbol{x}; \boldsymbol{w})\big) \\ &= -\log\sigma\big(yf(\boldsymbol{x}; \boldsymbol{w})\big) \\ &= \log\big(1 + \exp\big(-yf(\boldsymbol{x}; \boldsymbol{w})\big)\big).\end{aligned}$$

$1 - \sigma(x) = \sigma(-x).$

感受器 损失函数为

$$\mathcal{L}_p = \max\big(0, -yf(\boldsymbol{x}; \boldsymbol{w})\big).$$

软间隔支持向量机损失函数为

$$\mathcal{L}_{hinge} = \max\big(0, 1 - yf(\boldsymbol{x}; \boldsymbol{w})\big).$$

总结

线性模型	激活函数	损失函数	优化方法
线性回归	-	$(y - \boldsymbol{w}^\top \boldsymbol{x})^2$	最小二乘、梯度下降
Logistic 回归	$\sigma(\boldsymbol{w}^\top \boldsymbol{x})$	$\boldsymbol{y} \log \sigma(\boldsymbol{w}^\top \boldsymbol{x})$	梯度下降
Softmax 回归	$\mathrm{softmax}(\boldsymbol{W}^\top \boldsymbol{x})$	$\boldsymbol{y} \log \mathrm{softmax}(\boldsymbol{W}^\top \boldsymbol{x})$	梯度下降
感知器	$\mathrm{sgn}(\boldsymbol{w}^\top \boldsymbol{x})$	$\max(0, -y\boldsymbol{w}^\top \boldsymbol{x})$	随机梯度下降
支持向量机	$\mathrm{sgn}(\boldsymbol{w}^\top \boldsymbol{x})$	$\max(0, 1 - y\boldsymbol{w}^\top \boldsymbol{x})$	二次规划、SMO 等

谢谢！